从区间校准到可复核决策

高校食堂档口备餐减损的方法、实验与边界

食刻有数（FOODWISE） · 2026 年 10 月

食刻有数（FOODWISE）技术研究报告 · v2 · 2026-10-27

摘要

高校食堂中小档口的备餐决策长期依赖经验系数：按历史销量加一个固定安全边际。这种做法在成本结构稳定时尚可，但当折价比例、剩余可售概率或学生客流发生偏移时，安全系数会系统性偏离最优备餐量。本文报告食刻有数 v2 的四项工作。

第一，把点预测量化为**分层保形分位回归 + 自适应保形推断（CQR + ACI）**的 90% 预测区间，并按“星期 × 品类”做收缩分层，使区间覆盖率从原始分位模型的 57.7% 提升到 96.7%（测试集 390 条，$\alpha = 0.1$），代价是区间宽度从 0.128 增至 0.284（每百份）。

第二，把区间转成备餐量：以临界比 $\rho = C_u/(C_u+C_o)$ 求报童解，再叠加最小批量与产能约束，形成可解释的分批建议。

第三，在成本回测中比较四种策略。基准场景（临界比 0.886）下，固定 +10% 安全系数的 regret 为 1.66%，校准报童为 1.48%（差 0.18 个百分点）；当临界比降到 0.661（剩余几乎不可回收）时，差距扩大到 3.22 个百分点（95% 区间 [2.77, 3.71]）。**校准的收益是条件性的，不是普遍增益**：在基准场景下未校准 σ 的报童策略甚至略优于校准版（0.42 个百分点）。

第四，回答评审最关心的因果问题。我们用 120 次合成序列恢复实验评估两种归因方法：ITS（分段回归 + Newey-West）在真值 −5pp 时平均偏差 −0.12pp、区间覆盖率 92.5%、功效 100%；轻量 BSTS 偏差 −0.72pp、覆盖率仅 82.5%，因此只作敏感性对照。随后在真实台账（14 个营业日、**期间无任何干预**）上做负对照：按第 8 天分段仍会得到 −9.31pp（95% 区间 [−11.93, −6.69]）的“显著”下降。这说明现有设计**无法识别干预效果**（`verdict = not_identifiable`）：该数据只能识别约 6.46pp 以上的变化，要识别 5pp 级效果至少需要 35 个营业日。

本文的贡献不在于提出新的统计方法，而在于把一个常见的工程捷径——“上线后剩余率下降，就宣称减损成效”——拆成可复现的反例，并给出一条可执行的证据路线：区间要校准、决策要按成本算、因果要有对照。全部数字由仓库内脚本生成，命令见附录 A。

关键词：保形预测；分位回归；报童模型；中断时间序列；负对照；食品减损

1 问题与定位

1.1 场景

单校、单档口、日粒度。每个营业日按菜品记录：计划量、实际备餐量、售出量、折价售出量、剩余量、收入、天气与校园事件。菜品 7 道、档口 4 个、演示台账 98 条（14 个营业日，2026-07-07 至 2026-07-20）。

1.2 三个真实约束

1. 1. **样本极短**。14 个营业日不足以支撑星期效应调整，更不足以做因果识别。任何“减损 30%”式结论都不可信。
2. 2. **标签是派生的**。建模所用 `finetune_uwaste.parquet`（2600 行 × 24 特征）没有日期与餐次列，行序即日期序；标签由 `waste_rate` 派生而非现场观测销量。派生的标签只能验证方法，不能代表档口真实需求。
3. 3. **成本是情景值**。折价比例 0.5、剩余可售概率 0.6、缺货信任损失系数 0.3 均为设定值，未经食堂财务数据校准。

1.3 设计目标

不是“预测更准”，而是让每一个数字**可被第三方当场复核**：给定同一份产物与同一组输入，重算必须逐位一致；说不清的地方必须写明“不可识别”。

2 方法

2.1 分层保形分位回归 + 自适应保形推断

设点模型 $f(x)$ 与分位模型 $q_{\alpha/2}(x)$、$q_{1-\alpha/2}(x)$ 已由 LightGBM 训练。保形分位回归（CQR）在标定集上计算非一致性分数

$$E_i = \max\{ q_{\alpha/2}(x_i) - y_i,\ y_i - q_{1-\alpha/2}(x_i) \},$$

取 $\hat{Q}_{1-\alpha}(E)$ 为分数经验分位数，则区间为 $[q_{\alpha/2}(x) - \hat{Q},\ q_{1-\alpha/2}(x) + \hat{Q}]$。

我们做两点改造：

- **分层收缩**。按“星期 × 品类”共 21 层分别估计偏移 $\hat{Q}_s$，再向全局偏移收缩：$\tilde{Q}_s = (n_s \hat{Q}_s + \kappa \hat{Q}_{global})/(n_s + \kappa)$，取 $\kappa = 20$。样本少的层自动退回全局值，避免小样本层给出荒谬区间。
- **ACI 在线修正**。对每次新观测按 $\alpha_{t+1} = \alpha_t + \gamma(\alpha - err_t)$ 更新名义错误率，其中 err_t 为区间是否漏掉真值。部署配置使用一次性 ACI（`cqr+stratified-aci`），最终 α 从 0.10 漂移到 0.154，说明分布确有偏移、在线修正在起作用。

2.2 成本感知决策

由区间得到中心 $\hat{\mu}$ 与尺度 $\hat{\sigma}$，按临界比求报童解：

$$q^* = \hat{\mu} + \hat{\sigma}\, \Phi^{-1}\left(\frac{C_u}{C_u + C_o}\right),$$

其中 C_u 为缺货单位损失（含信任损失系数 λ），C_o 为剩余单位损失（计入折价回收）。随后施加最小批量（5 份）与产能上限（250 份），并按“首锅 + 补餐”拆分，给出可打印的执行单。

关键取舍：q^* 可能落在统计区间之外。这不是模型越界，而是成本驱动——当剩余损失远小于缺货损失时，最优解本就应该高于 P95。界面上直接标注“建议量高于区间上限：100 > 97”，而不是把区间偷偷拉宽。

2.3 三引擎与哈希校验

系统实现三个决策引擎，共用同一套分位模型，差异只在是否校准：

引擎	区间方法	用途
`rule`	固定 +10% 安全系数	现状基线
`quantile`	原始分位（未校准）	对照，展示“不校准会怎样”
`calibrated-quantile`	CQR + 分层收缩 + ACI	部署

启动时校验清单中的 `artifact_sha256`、分位模型 `sha256`；不匹配则拒绝加载并**降级到 `rule` 引擎**（页面明确提示降级原因），而不是带病出数。每次决策留痕 24 维输入、引擎、模型版本与建议量，支持 `/replay` 逐位重算。

2.4 归因设计

ITS（分段回归）：

$$y_t = \beta_0 + \beta_1 t + \beta_2 post_t + \beta_3 (t - t_0) post_t + \Sigma_{k=1}^{6} \gamma_k D_{kt} + \varepsilon_t,$$

β_2 即水平跳变，标准误用 Newey-West HAC（滞后按 $4(n/100)^{2/9}$ 选取）。

轻量 BSTS：状态向量 $[\mu_t, \delta_t, \gamma_{1:6}]$，$\mu_t$ 为局部水平（随机游走 + 过程噪声），δ_t 为处理效应、γ 为星期效应（均为静态系数），观测方程 $y_t = \mu_t + \delta_t post_t + \Sigma \gamma_k D_{kt} + \varepsilon_t$，超参用 Nelder-Mead 极大化似然。

恢复实验：合成周日序列（基准 300 份/天、星期效应 [0,4,6,8,20,26,10]、缓漂移、σ≈11），已知效应 0 / −5 / −10pp，各 120 次重复，比较偏差、RMSE、95% 区间覆盖率与功效。

负对照：在真实台账上假定一个不存在的干预起点，看方法会不会“测出”效应。

3 实验设置

项目	取值
建模数据	`finetune_uwaste.parquet`，2600 行 × 24 特征
切分	时间顺序：训练 1819 / 校准 391 / 测试 390
名义覆盖率	$1-\alpha=90\%$
区间指标	PICP（覆盖率）、PINAW（宽度）、Winkler 分数
决策指标	regret、每百份损失、缺货率、剩余率
成本假设	折价 0.5、剩余可售 0.6、缺货 $\lambda=0.3$、最小批量 5、产能 250
自助法	分块 bootstrap，块长 14，1000 次
随机种子	20261027（归因实验 120 次重复共用同一序列族）

Winkler 分数（$\alpha=0.1$）定义为

$$W = (u - l) + (2)/(\alpha)(l - y)1\{y < l\} + (2)/(\alpha)(y - u)1\{y > u\},$$

同时惩罚宽区间与漏出，是“又窄又准”的单一标量。

4 结果

4.1 区间质量

方法	PICP90	PINAW90	Winkler90	说明
原始分位（未校准）	57.69%	0.1278	29.87	严重低估不确定性
CQR 全局偏移	97.44%	0.2966	19.75	过度覆盖，浪费宽度
CQR + 分层收缩（部署）	**96.67%**	**0.2844**	**19.01**	覆盖率与宽度折中最优
CQR + ACI（一次性）	96.67%	0.2851	19.19	最终 α 漂移到 0.154
滚动重校准（每 25 步）	96.41%	0.2851	19.19	与一次性 ACI 接近
滚动 + ACI	95.90%	0.2767	18.84	更窄但略欠覆盖
滑动窗口（150）	92.56%	0.2560	18.48	覆盖最接近名义值

读法：未校准区间只覆盖 57.7%，意味着“十次里有四次把真实销量挡在门外”；校准后覆盖率回到 96.7%。**更宽的区间不是退步，而是把不确定性说清楚**——在备餐决策里，一个偏窄的区间会让人误以为“算准了”，从而按错误的临界比下单。

4.2 决策成本

基准场景（临界比 0.886，共 390 条测试样本）：

策略	regret	每百份损失（元）	缺货率	剩余率	平均备餐
固定 +10%（现状）	1.66%	12.85	0.0%	9.73%	82.09
报童 + 未校准 σ	**1.23%**	9.55	0.43%	5.01%	77.68
报童 + 校准 σ（部署）	1.48%	11.47	0.0%	8.98%	81.41
报童 + 校准 + 批量约束	2.01%	15.59	0.0%	11.67%	83.90

成本结构扫描（剩余可售概率 → 临界比 → regret）：

剩余可售	临界比	固定 +10%	报童 + 校准	差值
0.0	0.661	6.62%	**3.39%**	−3.23pp
0.2	0.722	4.97%	2.88%	−2.09pp
0.4	0.796	3.31%	2.24%	−1.07pp
0.6	0.886	1.66%	1.48%	−0.18pp
0.7	0.940	0.83%	0.95%	+0.12pp

这不是一条“我们的方法更好”的单调曲线。临界比越高（剩余越容易回收、缺货代价相对越大），固定安全系数反而越接近最优；当临界比 0.94 时校准策略落后 0.12pp。而在剩余几乎不可回收（临界比 0.661）时，固定系数的 regret 是校准策略的近两倍。

同一份数据里，未校准 σ 的报童在基准场景还略优于校准 σ（1.23% vs 1.48%），因为校准把区间拉宽、抬高了建议量，而该场景下缺货代价并不高。**结论应写成“校准在成本结构不利时价值最大”，而不是“校准总是更好”**。

4.3 归因：方法能不能用，数据够不够用

恢复实验（各 120 次）：

真实效应	方法	平均估计	偏差（pp）	RMSE（pp）	95% 覆盖率	功效
0 pp	ITS + HAC	−0.12	−0.12	1.09	92.5%	7.5%
0 pp	轻量 BSTS	−0.73	−0.73	1.04	81.7%	18.3%
−5 pp	ITS + HAC	−5.12	−0.12	1.09	92.5%	100%
−5 pp	轻量 BSTS	−5.72	−0.72	1.04	82.5%	100%
−10 pp	ITS + HAC	−10.12	−0.12	1.09	92.5%	100%
−10 pp	轻量 BSTS	−10.72	−0.72	1.04	82.5%	100%

真值为 0 时的假阳性率：ITS 10.0%、BSTS 15.0%（各 60 次）。BSTS 区间系统性偏窄、有效覆盖率只有 82%，因此**只作敏感性对照，不进结论**。

真实台账负对照（14 个营业日，期间无任何干预）：

- ITS 按第 8 天分段得到 **−9.31pp**，95% 区间 [−11.93, −6.69]，$p < 0.001$。

- 原因不是干预，而是 7 月中旬起剩余率本身在下降（8.9% → 3.4%），分段回归把趋势读成了跳变。
- 该序列残差 $\sigma = 3.46$pp，14 个营业日在 80% 功效下只能识别 **6.46pp** 以上的变化；要识别 5pp 级效果，**至少 35 个营业日**。
- 判定：`not_identifiable`。系统据此**拒绝**输出任何减损成效结论。

这条负对照是本文最重要的结果：它说明“上线前后对比”在这个数据规模下必然给出假阳性，而**一个好系统应该在算不出来的时候说算不出来**。

4.4 工程一致性

- **重放一致性**：每个决策记录保存 24 维输入、引擎与模型版本；`/replay` 用当前产物重算并比对。曾出现“用错引擎重放”（quantile 记录被 calibrated 引擎重算，$100 \neq 90$），已按 `record.engine()` 分派并补回归测试。
- **三引擎对照**：同一菜品同一目标日，校准引擎给出区间 [64, 97]、建议 100 份（覆盖率 96.7%）；对照引擎给出 [73, 88]、建议 90 份（实测覆盖率 57.7%）。界面同时展示两者，让“校准改变结论”这件事可被直接观察。
- **测试规模**：Java 17 个测试套件 / 59 个用例，Python 101 个用例，清单契约校验 1 项，全部通过。

5 讨论

5.1 什么时候校准有价值

把 4.2 的表按临界比排序可以看出：校准的收益随“缺货相对昂贵程度”上升。当剩余可回收、缺货代价低时，固定安全系数恰好落在最优附近；当剩余不可回收（临界比 0.66）时，固定系数多做的每一份都是纯损失。因此产品上线时应先测两件事：**折价回收率**与**缺货的实际代价**，再决定是否启用成本感知决策。

5.2 为什么不用完整 BSTS

Brodersen 等的 BSTS 依赖 MCMC 与 spike-and-slab 先验做变量选择，工程上需要稳定复现与秒级响应。我们实现的是“局部水平 + 静态回归”的轻量版本，实测区间覆盖率 82%，低于名义值；在只有几十个观测点的校园场景里，先验与采样成本换不来精度。**选择 ITS + HAC 不是因为它先进，而是因为它在这个样本量下可被检验、可被解释**。

5.3 与"AI 备餐"叙事的距离

系统内部没有任何大模型参与决策，页面文案也不出现“AI/智能/算法”字样。定位是“把台账变成可复核的分批建议”：输入是台账与成本参数，输出是可打印的执行单与可重放的决策记录。这一点在申报材料中必须保持一致，否则一旦被问到“模型在哪”，叙事会崩。

6 限制与伦理

4. 1. **标签是派生的**。`finetune_uwaste.parquet` 无日期与餐次列，行序即日期序；标签由 `waste_rate` 派生。区间指标只反映方法在派生目标上的表现，不外推到现场销量。
5. 2. **成本参数未经校准**。折价 0.5、剩余可售 0.6、$\lambda = 0.3$ 为情景假设，regret 只反映策略相对排序。
6. 3. **无因果证据**。真实台账只有 14 个营业日且不含干预；负对照已证明该设计无法识别效果。任何“减损 X%”表述都不成立。
7. 4. **BSTS 为实现级近似**。无 MCMC、无变量选择，覆盖率低于名义值。
8. 5. **恢复实验的合成设定由我们选择**。真实校园的考试周、天气冲击、促销更复杂，偏差可能更大。
9. 6. **合规**。项目以《中华人民共和国反食品浪费法》（2021）为价值锚点，但不宣称合规认证；数据来源与许可见 `docs/数据来源与许可说明`，公开数据集仅用于方法验证。

7 结论

本文把“高校食堂备餐减损”拆成三个可验证的问题：区间准不准、决策省不省钱、因果说不说得清。

- 区间：CQR + 分层收缩把覆盖率从 57.7% 提到 96.7%，Winkler 从 29.87 降到 19.01。
- 决策：校准的收益是条件性的，在临界比 0.661 时比固定安全系数少 3.22pp regret，在 0.94 时反而落后 0.12pp。
- 因果：现有数据不可识别。负对照在无干预的数据上“测出” −9.31pp，要求至少 35 个营业日才能识别 5pp 级效果。

这三条结论都不漂亮，但都可复现。对一个面向真实食堂的产品而言，“知道自己什么时候算不出来”比多报一个百分点更有价值。

参考文献

按作者—年份—标题—发表处列出；卷期页码请以原文为准，本文不代替原文引用。

10. 1. Koenker, R., Bassett, G. (1978). Regression Quantiles. *Econometrica*.
11. 2. Newey, W. K., West, K. D. (1987). A Simple, Positive Semi-Definite, Heteroskedasticity and Autocorrelation Consistent Covariance Matrix. *Econometrica*.
12. 3. Gneiting, T., Raftery, A. E. (2007). Strictly Proper Scoring Rules, Prediction, and Estimation. *Journal of the American Statistical Association*.
13. 4. Brodersen, K. H., Gallusser, F., Koehler, J., Remy, N., Scott, S. L. (2015). Inferring Causal Impact Using Bayesian Structural Time-Series Models. *Annals of Applied Statistics*.
14. 5. Bernal, J. L., Cummins, S., Gasparrini, A. (2017). Interrupted Time Series Regression for the Evaluation of Public Health Interventions: A Tutorial. *International Journal of Epidemiology*.
15. 6. Romano, Y., Patterson, E., Candès, E. J. (2019). Conformalized Quantile Regression. *NeurIPS*.
16. 7. Tibshirani, R. J., Barber, R. F., Candès, E. J., Ramdas, A. (2019). Conformal Prediction Under Covariate Shift. *NeurIPS*.
17. 8. Gibbs, I., Candès, E. J. (2021). Adaptive Conformal Inference Under Distribution Shift. *NeurIPS*.
18. 9. 全国人民代表大会常务委员会 (2021). 《中华人民共和国反食品浪费法》.

附录 A 复现命令

```
cd 项目代码

# 1) 区间校准产物 + 测试对照样本
modeling/.venv/Scripts/python.exe modeling/scripts/32_fit_intervals.py

# 2) 四方法决策回测（含成本扫描与分块 bootstrap）
modeling/.venv/Scripts/python.exe modeling/scripts/33_decision_backtest.py

# 3) 归因恢复实验 + 负对照（约 2 分钟）
modeling/.venv/Scripts/python.exe modeling/scripts/34_attribute.py --reps 120

# 4) 清单契约与哈希绑定校验
modeling/.venv/Scripts/python.exe modeling/scripts/30_verify_manifest.py

# 5) 测试
modeling/.venv/Scripts/python.exe -m unittest discover -s modeling/tests
./gradlew.bat test

# 6) 起服务并在浏览器核对
./gradlew.bat bootRun           # http://127.0.0.1:8089
cd frontend && node verify-v2.cjs && node verify-attribution.cjs && node verify-
reports.cjs
```

附录 B 产物清单

产物	路径	用途
模型清单	`src/main/resources/modeling/model_manifest.json`	版本、方法、哈希绑定
校准产物	`src/main/resources/modeling/campus_interval_calibration.json`	分层偏移、ACI 状态
区间指标	`.../interval_backtest_metrics.json`	七方法 PICP/PINAW/Winkler
决策指标	`.../decision_backtest_metrics.json`	四策略 regret、成本扫描
归因指标	`.../attribution_backtest.json`	恢复实验、安慰剂、负对照
测试对照样本	`src/test/resources/modeling/quantile_parity_fixture.json`	Python/Java 分位一致性
逐条测试预测	`modeling/data/03_output/interval_test_predictions.csv`	390 条区间明细

清单登记的哈希（2026-10-27）：

- 校准产物 `artifact_sha256`：`1047da73b650a98e0548946a8af084a330d1b8a4e2c6ba9b5bd31bffe0296cdf`

- 分位模型 q0.05 sha256：
  b2254841502bd625d2c2f45c80f0dd69ab48918c7220c200e5641d8e1af238b4
- 分位模型 q0.95 sha256：
  2c2a4eae77ac21d0b17cbab089fc94858fbb84bd5ce5d1cde5dc8c12de548a89

附录 C 术语对照

术语	含义	站内对应
备餐计划	按菜品给出的分批建议量	做备餐计划
校准区间	CQR + 分层 + ACI 后的 90% 区间	计划页区间带
建议执行率	确认执行量 / 建议量	经营复盘
台账	当餐盘点与最终结果记录	录台账
减损	剩余量与剩余成本下降（描述性）	不做因果声称